

인간형 기억 재구성 기반 LLM 아키텍처 설계 문서

v1.0

개요

본 구조는 기존 LLM의 핵심 문제인 환각(Hallucination), 장기기억 불안정, 압축 기억 왜곡, 불확실성 은폐, 세션 단절을 줄이기 위해 설계된 탐색·검증 중심 기억 재구성 구조이다.

핵심 철학은 생성보다 탐색 우선이며, 기억을 단순 저장·재생이 아니라 압축 → 단서 확보 → 원본 재검색 → 검증 → 재구성 과정으로 취급한다.

1. 목표

- 환각 감소
- 장기 기억 유지
- 인간형 회상 구현
- 검증 가능한 기억 구조
- 질문 비용 제어
- 오류 비용 분산

2. 기존 구조의 문제

기존 LLM 구조는 입력 → 생성 → 응답 형태이며, 환각·세션 의존·압축 왜곡·확신 과잉 문제가 존재한다.

3. 제안 구조 개요

사용자 입력

↓

압축 기억 검색

↓

불확실성 평가

↓

질문 예산 확인

↓

필요시 사용자 질문

↓

원본 로그 재검색

↓

검증

↓

응답 생성

4. 기억 계층 구조

L0: 원본 로그 계층

L1: 요약 기억 계층

L2: 추상 기억 계층

L3: 망각 흔적 계층

5. 압축 정책

삭제보다 단계적 열화(degradation)를 우선한다.

원본 → 요약 → 추상화 → 흔적

6. 회상 구조

질문 → 압축 기억 검색 → 단서 질문 → 원본 재검색 → 검증 → 응답 생성

7. 질문 예산 시스템

질문은 무료 행동이 아니라 정확도 향상을 위한 비용 자원으로 취급한다.

예시:

- 저마찰: 10회당 1회
- 균형: 5회당 1회
- 정확도 우선: 3회당 1회
- 검증 우선: 1회당 1회

8. 불확실성 기반 행동 정책

- 고신뢰: 직접 응답
- 중간신뢰: 불확실성 표현
- 저신뢰: 질문 수행
- 극저신뢰: 회상 보류

9. 질문 생성 규칙

유도 질문 금지.

잘못된 예:

"카드 이야기였지?"

올바른 예:

"카드 관련이었나, 게임 관련이었나?"

10. 유사 기억 충돌 처리

유사 기억들을 흐름(flow) 단위로 묶어 사용자에게 후보 형태로 제시한다.

11. 환각 억제 구조

정보 부족 → 질문 → 원본 탐색 → 검증 → 생성

12. 오류 유형 변화

없는 기억 생성(fabrication)보다 실제 기억 간 오연결(misassociation) 중심으로 오류 형태를 전환한다.

13. 인간-AI 공동 복원 구조

사용자를 단순 입력자가 아니라 기억 복원 단서 제공자로 취급한다.

14. 예상 문제점 및 대응

- 응답 속도 감소 → 임계값 보정
- 질문 피로 → 질문 예산 커스터마이징
- 압축 왜곡 → 디버그 및 재압축
- 사용자 오기억 → 원본 로그 기반 검증
- 유사 기억 충돌 → 흐름 단위 후보 제시

15. 디버그 및 보정 구조

압축 기억은 완전 신뢰 대상이 아니라 실험·보정 대상으로 취급한다.

16. 권장 구현 구조

최소 구현:

Python + SQLite + Chroma + LLM API

권장 구현:

Ollama + Qdrant + PostgreSQL + Memory Manager + Question Budget Manager

17. 핵심 차별점

질문을 정보 수집이 아니라 환각 억제용 비용 자원으로 사용한다.

18. 예상 연구 방향

- Interactive Retrieval
- Persistent Agent Memory
- Conversational Recall
- Hallucination Mitigation
- Human-like Recall Architecture

19. 결론

본 구조는 생성 중심 LLM을 탐색·검증 중심 기억 재구성 시스템으로 전환하려는 시도이다.